

Analizador Léxico e Sintático

Vitor Fernandes Dullens - 16/0148260

Universidade de Brasília

1 Introdução

Este relatório abordará sobre as primeiras etapas do processo de criação de um tradutor, que consiste na implementação do analisador léxico e sintático para uma linguagem específica, como apresentado no livro base da disciplina [ALSU07]. Neste documento serão descritos com detalhes a motivação por trás desta implementação, assim como a descrição das análises e instruções para a compilação e execução do programa. Também será apresentada uma descrição da linguagem a ser analisada.

2 Motivação

Na linguagem C, muitas vezes sentimos falta de operações que facilitam a utilização de conjuntos, como existem em outras linguagens de mais alto nível. Dito isso, a fim de facilitar essas operações, uma implementação de uma nova primitiva de dados para conjuntos foi proposta dentro da linguagem C – **set**, assim como operações para a mesma – **add**, **remove**, entre outras.

Abaixo segue um exemplo de código na nova linguagem proposta.

```
int main() {
    set s;
    s = EMPTY;

    add(1 in add(2 in add(3 in s)));
    /* s = (1, 2, 3) */

    remove(1 in s);
    /* s = (2, 3) */
}
```

Além de operações com conjuntos, também foi adicionado um tipo polimórfico – **elem** que facilita, também, o uso de conjuntos. Mais detalhes sobre a linguagem podem ser encontrados no apêndice A.

3 Descrição da análise léxica

Para a implementação do analisador léxico foi utilizado o programa *Fast Lexical Analyzer Generator* - FLEX [Est17], que consiste em uma ferramenta geradora de programas que reconhecem padrões léxicos em textos.

No arquivo de nome `lexico.1` é possível visualizar as regras léxicas. Para o tratamento das mesmas são declaradas expressões regulares (regex) que as identificam e após essas declarações existe uma sequência de ações que o analisador executa ao encontrar uma regra. Além das regras e ações, no arquivo `lexico.1` também foram definidas funções para leitura de arquivo, assim como duas variáveis `int linha`, `int coluna`, que representam, respectivamente, a linha e a coluna na qual está acontecendo a ação.

O analisador léxico também é responsável pela atribuição dos tokens que serão utilizados durante a análise sintática. Os tokens são declarados como uma `struct Lexema` que possui os parâmetros `char corpo[100]` que consiste no token propriamente dito, `int linha` e `int coluna` que, respectivamente, representam a linha e coluna daquele token. Essa `struct` é declarada no arquivo do analisador sintático, e pode ser utilizada no analisador léxico utilizando a variável global `yylval`.

4 Descrição da análise sintática

Para a implementação do analisador sintático foi utilizado o programa Bison [DS21], que consiste em um gerador de parser que utiliza de uma gramática livre do contexto para criar uma derivação LR. Para este trabalho foi utilizada a flag `%define lr.type canonical-lr` para que a derivação realizada seja a LR(1) canônica.

No arquivo de nome `sintatico.y` é possível visualizar a gramática presente no apêndice A com algumas modificações para se encaixar na sintaxe do próprio Bison.

4.1 Árvore Sintática

Pelo modo como é feito o parser pelo próprio Bison, é possível construir uma árvore sintática abstrata. Para isso, cada não terminal agora é um nó da árvore, e cada terminal é um símbolo, assim como será apresentado na Seção 4.2. Cada um desses nós, consiste em uma estrutura que armazena o símbolo (terminal), qual a regra que foi vista, o nó próximo e o filho. Com essas informações é possível realizar um caminho em profundidade a partir da raiz apresentando cada um dos nós que foram visitados e todos os detalhes necessários.

A Figura 1 representa a árvore gerada para um programa de entrada simples.

4.2 Tabela de Símbolos

Durante a passagem do analisador sintático, ele também é responsável por salvar os símbolos, afim de utiliza-los futuramente na análise semântica.

A tabela de símbolos consiste em uma lista, onde cada elemento é um símbolo que consiste em uma estrutura que armazena dados que podem ser úteis na próxima etapa do projeto, como o ID da variável ou função declarada, suas respectivas linha e coluna, tipo, se é uma função ou apenas variável e o escopo.


```

2. SYNTAX ERROR 5:21 - syntax error, unexpected ';',
   expecting ',', ' or ')'
SYNTAX ERROR 12:11 - syntax error, unexpected ';'

```

Basicamente, como é possível observar acima, os erros são apresentados e possuem a linha e coluna na qual eles pertencem (linha:coluna). O primeiro arquivo de erro - `erro1.c` - possui tanto erros léxicos, quando erros sintáticos, já o segundo arquivo - `erro2.c` - possui apenas erros sintáticos. Quando um arquivo possui erros não são apresentadas a tabela de símbolos nem a árvore sintática. Além disso, cada erro é apresentado seguido de uma descrição do mesmo.

6 Instruções para compilação e execução do programa

O programa foi criado e testado em um sistema operacional Linux - Ubuntu 20.04.1 LTS. É necessária a instalação do FLEX [Est17] e do BISON [DS21] para a compilação do programa. Ao executar o programa também deverá ser passado o arquivo que será analisado.

Comandos para compilação e execução:

```

$ bison syntax.y
$ flex lexical.l
$ gcc syntax.tab.c lex.yy.c tabela.c arvore.c
$ ./a.out tests/<nome-arquivo>.c

```

Outra alternativa para facilitar a compilação seria utilizar o comando `make`.

Referências

- [ALSU07] A.V. Aho, M.S. Lam, R. Sethi, and J.D. Ullman. *Compilers: Principles, Techniques, & Tools*. Pearson/Addison Wesley, 2nd edition, 2007.
- [DS21] C. Donnelly and R. Stallman. Bison - the yacc-compatible parser generator, 2021. Online; Acessado 18 de março de 2021
<https://www.gnu.org/software/bison/manual/bison.html>.
- [Est17] W. Estes. Flex: Fast lexical analyzer generator, 2017. Online; Acessado 21 de fevereiro de 2021
<https://github.com/westes/flex>.

A Gramática

$\langle \text{program} \rangle ::= \langle \text{declaration_list} \rangle$
 $\langle \text{declaration_list} \rangle ::= \langle \text{declaration} \rangle \langle \text{declaration_list} \rangle \mid \langle \text{declaration} \rangle$
 $\langle \text{declaration} \rangle ::= \langle \text{function_declaration} \rangle \mid \langle \text{var_declaration} \rangle$
 $\langle \text{var_declaration} \rangle ::= \langle \text{type} \rangle \langle \text{id} \rangle \text{' ;'}$
 $\langle \text{function_declaration} \rangle ::= \langle \text{type} \rangle \langle \text{id} \rangle \text{' (' } \langle \text{params_list} \rangle \text{')' } \langle \text{brackets_stmt} \rangle$
 $\quad \mid \langle \text{type} \rangle \langle \text{id} \rangle \text{' (' ' ' } \langle \text{brackets_stmt} \rangle$
 $\langle \text{params_list} \rangle ::= \langle \text{type} \rangle \langle \text{id} \rangle \text{' , ' } \langle \text{param_list} \rangle \mid \langle \text{type} \rangle \langle \text{id} \rangle$
 $\langle \text{stmts} \rangle ::= \langle \text{stmt} \rangle \langle \text{stmts} \rangle \mid \langle \text{stmt} \rangle$
 $\langle \text{stmt} \rangle ::= \langle \text{for_stmt} \rangle \mid \langle \text{if_else_stmt} \rangle \mid \langle \text{return_stmt} \rangle \mid \langle \text{io_stmt} \rangle$
 $\quad \mid \langle \text{brackets_stmt} \rangle$
 $\quad \mid \langle \text{exp_stmt} \rangle$
 $\quad \mid \langle \text{set_stmt} \rangle$
 $\quad \mid \langle \text{var_declaration} \rangle$
 $\quad \mid \langle \text{assignment} \rangle \text{' ;'}$
 $\langle \text{assignment} \rangle ::= \langle \text{id} \rangle \text{' = ' } \langle \text{exp} \rangle$
 $\langle \text{brackets_stmt} \rangle ::= \text{' {' } \langle \text{stmts} \rangle \text{' } \text{' } \text{' }$
 $\langle \text{io_stmt} \rangle ::= \text{read ' (' } \langle \text{id} \rangle \text{')' ' ;'}$
 $\quad \mid \text{write ' (' } \langle \text{string} \rangle \mid \langle \text{exp} \rangle \text{')' ' ;'}$
 $\quad \mid \text{writeln ' (' } \langle \text{string} \rangle \mid \langle \text{exp} \rangle \text{')' ' ;'}$
 $\langle \text{for_stmt} \rangle ::= \text{for ' (' } \langle \text{assignment} \rangle \text{' ;' } \langle \text{exp} \rangle \text{' ;' } \langle \text{assignment} \rangle \text{')' } \langle \text{stmt} \rangle$
 $\langle \text{if_else_stmt} \rangle ::= \text{if ' (' } \langle \text{exp} \rangle \text{')' } \langle \text{stmt} \rangle$
 $\quad \mid \text{if ' (' } \langle \text{exp} \rangle \text{')' } \langle \text{brackets_stmt} \rangle \text{ else } \langle \text{stmt} \rangle$
 $\langle \text{return_stmt} \rangle ::= \text{return ' ;' } \mid \text{return } \langle \text{exp} \rangle \text{' ;'}$
 $\langle \text{set_stmt} \rangle ::= \text{forall ' (' } \langle \text{id} \rangle \text{ in } \langle \text{set_exp} \rangle \text{')' } \langle \text{stmt} \rangle$
 $\langle \text{exp_stmt} \rangle ::= \langle \text{exp} \rangle \text{' ;' } \mid \text{' ;'}$
 $\langle \text{exp} \rangle ::= \langle \text{or_exp} \rangle \mid \langle \text{set_exp} \rangle$
 $\langle \text{set_exp} \rangle ::= \text{add ' (' } \langle \text{set_in_exp} \rangle \text{')'}$
 $\quad \mid \text{remove ' (' } \langle \text{set_in_exp} \rangle \text{')'}$
 $\quad \mid \text{exists ' (' } \langle \text{set_in_exp} \rangle \text{')'}$
 $\langle \text{set_in_exp} \rangle ::= \langle \text{or_exp} \rangle \text{ in } \langle \text{set_exp} \rangle$
 $\langle \text{or_exp} \rangle ::= \langle \text{or_exp} \rangle \text{' || ' } \langle \text{and_exp} \rangle \mid \langle \text{and_exp} \rangle$
 $\langle \text{and_exp} \rangle ::= \langle \text{and_exp} \rangle \text{' \&\& ' } \langle \text{relational_exp} \rangle \mid \langle \text{relational_exp} \rangle$

$$\begin{aligned}
\langle relational_exp \rangle &::= \langle relational_exp \rangle \langle relational_op \rangle \langle sum_exp \rangle \mid \langle sum_exp \rangle \\
\langle relational_op \rangle &::= '<' \mid '>' \mid '>=' \mid '<=' \mid '==' \mid '!=' \\
\langle sum_exp \rangle &::= \langle sum_exp \rangle '+' \langle mul_exp \rangle \\
&\mid \langle sum_exp \rangle '-' \langle mul_exp \rangle \\
&\mid \langle mul_exp \rangle \\
\langle mul_exp \rangle &::= \langle mul_exp \rangle '*' \langle primal_exp \rangle \\
&\mid \langle mul_exp \rangle '/' \langle primal_exp \rangle \\
&\mid \langle unary_exp \rangle \\
\langle unary_exp \rangle &::= '!'? \langle primal_exp \rangle \mid '-' \langle primal_exp \rangle \\
&\mid '!'? \langle id \rangle '(' \arg_list ')', \\
&\mid '!'? \langle id \rangle '(' ')', \\
&\mid '!'? \text{is_set} '(' \langle id \rangle \mid \langle set_exp \rangle ')', \\
\langle primal_exp \rangle &::= \langle id \rangle \mid \langle const \rangle \mid '(' \langle exp \rangle ')', \\
\langle arg_list \rangle &::= \langle exp \rangle, \langle arg_list \rangle \mid \langle exp \rangle \\
\langle type \rangle &::= \langle basic_type \rangle \mid \langle elem_type \rangle \mid \langle set_type \rangle \\
\langle const \rangle &::= \langle int_const \rangle \mid \langle float_const \rangle \mid \langle empty_const \rangle \\
\langle int_const \rangle &::= \langle digit \rangle + \\
\langle float_const \rangle &::= \langle digit \rangle + '.' \langle digit \rangle^* \\
\langle empty_const \rangle &::= 'EMPTY' \\
\langle elem_type \rangle &::= \text{elem} \\
\langle set_type \rangle &::= \text{set} \\
\langle int_type \rangle &::= \text{int} \\
\langle float_type \rangle &::= \text{float} \\
\langle string \rangle &::= .* \mid '.*' \\
\langle id \rangle &::= [a-zA-Z_][_a-zA-Z-Z]* \\
\langle number \rangle &::= [0-9]
\end{aligned}$$