# **Tradutor**

Vitor Fernandes Dullens - 16/0148260

Universidade de Brasília

### 1 Introdução

Este relatório abordará as primeiras etapas do processo de criação de um tradutor, que consistem na implementação do analisador léxico, sintático, semântico e da geração do código de três endereços para uma linguagem específica, como apresentado no livro base da disciplina [ALSU07]. Neste documento serão descritos com detalhes a motivação por trás desta implementação, assim como a descrição das análises e instruções para a compilação e execução do programa. Também será apresentada uma descrição da linguagem a ser analisada.

# 2 Motivação

Na linguagem C, muitas vezes sentimos falta de operações que facilitam a utilização de conjuntos, como existem em outras linguagens de mais alto nível. Dito isso, a fim de facilitar essas operações, uma implementação de uma nova primitiva de dados para conjuntos foi proposta dentro da linguagem C – set, assim como operações para a mesma – add, remove, entre outras.

Abaixo segue um exemplo de código na nova linguagem proposta.

```
int main() {
    set s;
    s = EMPTY;

    add(1 in add(2 in add(3 in s)));
    /* s = (1, 2, 3) */

    remove(1 in s);
    /* s = (2, 3) */

    return 0;
}
```

Além de operações com conjuntos, também foi adicionado um tipo polimórfico – elem que facilita, também, o uso de conjuntos. Mais detalhes sobre a linguagem podem ser encontrados no Apêndice A.

## 3 Descrição da análise léxica

Para a implementação do analisador léxico foi utilizado o programa Fast Lexical Analyzer Generator - FLEX [Est17], que consiste em uma ferramenta geradora de programas que reconhecem padrões léxicos em textos.

No arquivo de nome lexico.1 é possível visualizar as regras léxicas. Para o tratamento das mesmas são declaradas expressões regulares (regex) que as identificam e após essas declarações existe uma sequência de ações que o analisador executa ao encontrar uma regra. Além das regras e ações, no arquivo lexico.1 também foram definidas duas variáveis int linha, int coluna, que representam, respectivamente, a linha e a coluna na qual está acontecendo a ação, e uma variável externa int erros que abriga a quantidade de erros que foram encontrados durante toda a execução das análises.

O analisador léxico também é responsável pela construção dos tokens que serão utilizados durante a análise sintática. Os tokens são declarados como uma struct Lexema que possui os parâmetros char\* corpo que consiste no lexema propriamente dito, int linha e int coluna que, respectivamente, representam a linha e coluna daquele token. Essa struct é declarada no arquivo do analisador sintático e pode ser utilizada no analisador léxico utilizando a variável global yylval.

# 4 Descrição da análise sintática

Para a implementação do analisador sintático foi utilizado o programa Bison [DS21], que consiste em um gerador de analisador que utiliza de uma gramática livre do contexto para criar um autômato capaz de reconhecer esta linguagem. Para este trabalho foi utilizada a flag %define lr.type canonical-lr para que a derivação realizada seja a LR(1) canônica.

No arquivo de nome sintatico. y é possível visualizar a gramática presente no Apêndice A com algumas modificações para se encaixar na sintaxe do próprio Bison.

#### 4.1 Árvore Sintática

Pelo modo como é feita a análise pelo autômato, é possível construir uma árvore sintática abstrata. Para isso, cada não terminal agora é um nó da árvore e cada terminal é um símbolo, assim como será apresentado na Seção 4.2. Cada um desses nós, consiste em uma estrutura que armazena o símbolo (terminal), qual a regra que foi vista, o nó próximo e o filho. Com essas informações é possível realizar um caminho em profundidade a partir da raiz apresentando cada um dos nós que foram visitados e todos os detalhes necessários.

A Figura 1 representa a árvore gerada para um programa de entrada simples.

Figura 1. Árvore Sintática Abstrata para uma entrada simples

#### 4.2 Tabela de Símbolos

Durante a passagem do analisador sintático, ele também é responsável por salvar os símbolos, a fim de utilizá-los futuramente na análise semântica.

A tabela de símbolos é uma lista de símbolos, onde um símbolo consiste em uma estrutura que armazena dados que podem ser úteis na próxima etapa do projeto, como o ID da variável ou função declarada, suas respectivas linha e coluna, tipo, se é uma função, variável ou um parâmetro, e o escopo.

TABELA DE SIMBOLOS								
= IDENTIFICADOR	L	INHA: COLUNA	-	TIPO	1	PARAM/VAR/FUNC	1	ESCOPO =
	==		=   =		: :		:   =	
f		1:5	-	INT	1	FUNC	1	0
x		1:18	-	INT	1	PARAM	1	1
a		1:11	-	INT	1	PARAM	1	1
main		5:5	-	INT	1	FUNC	1	0
l x		6:9	-	INT	1	VAR	1	2
s		7:9	-	SET	1	VAR	1	2
l a		9:11	-	FLOAT	١.	VAR	1	2
l p		11:11	-	ELEM	1	VAR	1	3
==========	===	========	==:		=		:=:	

Acima é possível visualizar um exemplo da tabela de símbolos que é apresentada ao final do programa. Vale notar a presença de funções (FUNC), parâmetros (PARAM) e variáveis (VAR), contendo também seus respectivos escopos, tipos, identificadores e posições.

### 5 Descrição da análise semântica

Como já se sabe, a análise semântica é responsável por verificar se o programa "faz sentido" ou não, ou seja, verificação de tipos de variáveis, realização de

#### 4 Dullens, V.

coerções de tipo, verificação de quantidade de parâmetros, se variáveis foram previamente declaradas, entre outras.

Dito isso, como o automato construído pelo Bison [DS21] já faz uma passagem por todo o programa na análise sintática, utilizei desta mesma passagem para fazer a maior parte das verificações necessárias da análise semântica. Abaixo seguem subseções sobre as principais regras utilizadas para esta etapa.

### 5.1 Regras de escopo

Para a implementação dos escopos, foi utilizada a estrutura de dados de pilha. Como em C não existe uma estrutura pronta para isso, foi criado uma abstração desta estrutura, utilizando uma lista junto com um índice, onde o índice aponta sempre para o último elemento da lista.

As funcionalidades do escopo são como as esperadas em um programa em C, na Seção 4.2 é possível visualizar a tabela de símbolos para um dos arquivos testes: Nela se encontram o escopo de cada uma das variáveis, parâmetros e funções.

As verificações feitas durante a análise semântica consistem em verificar se uma variável ou função foi previamente declarada, se não existem múltiplas declarações da mesma variável no mesmo escopo ou múltiplas declarações da mesma função e, também, a verificação se a função main foi definida. Todas essas verificações são feitas com o auxílio da tabela de símbolos, que abriga todos os dados necessários para esta análise.

### 5.2 Regras de passagem de parâmetros

Quando uma função é declarada, são associados seus parâmetros a ela, ou seja, cada símbolo da tabela que for uma função, acompanha uma lista de parâmetros. Além disso, os parâmetros são apresentados na tabela de símbolos e propriamente identificados como é possível ver na Seção 4.2.

Ao ser chamada, uma função passa por duas verificações, a primeira consiste em verificar se a quantidade de argumentos é igual a quantidade de parâmetros que foram declarados na criação da função, caso isso não seja correspondido, o programa gera um erro, apresentando quantos parâmetros foram passados e quantos são esperados para aquela função. A segunda verificação, é a análise dos tipos, ela será mais abordada na Seção 5.3, mas rapidamente, esta etapa consiste em verificar se os tipos dos argumentos correspondem aos tipos declarados na função, se os tipos não forem iguais, tenta-se fazer a conversão de tipos, caso isso não seja possível, por incompatibilidade dos tipos, um erro é lançado, apresentando o tipo passado e o tipo esperado.

### 5.3 Decisões sobre conversões de tipos

Como apresentado anteriormente, a motivação para esta linguagem é facilitar a utilização de conjuntos. Dito isso, os tipos presentes na linguagem são int,

float, set e elem, sendo os dois últimos destinados para a utilização de conjuntos.

Para realizar as coerções necessárias, foram adicionadas informações de tipos para cada nó da árvore, como é possível visualizar na Figura 1. Quando há uma coerção de tipo, ela é sinalizada como CAST e em seguida é especificado qual coerção foi realizada, por exemplo, int2float significa que o nó era do tipo int e que fora convertido para o tipo float.

Alguns tipos e funções tem suas particularidades. Por exemplo, não é possível converter um **int** ou um **float** para o tipo **set**, visto que são tipos muito distintos. Abaixo seguem algumas das regras específicas para cada tipo:

- int pode ser convertido para float, e vice-versa;
- O tipo elem pode ser convertido para qualquer um dos outros tipos, e viceversa:
- A constante EMPTY é tratada como vazio (NULL) e só pode ser utilizada em tipos elem ou set;
- Funções como is\_set ou para verificação de uma variável dentro de um set
   (e.g: 1 in s) retornam o tipo int.
- Funções como add e remove retornam o tipo set e na parte direita dessas expressões sempre é esperado o tipo set;
- A função exists retorna o tipo elem;
- Não é possível realizar operações aritméticas com o tipo set;
- Operações lógicas (&& e ||) e relacionais (==, !=, etc) sempre retornam o tipo int, contudo nas operações relacionais dependem do tipo das expressões, enquanto operações lógicas podem ser realizadas com qualquer tipo (e.g. int i; set s; (s && a);

### 6 Geração de Código Intermediário

A geração do código intermediário foi feita baseada nas instruções disponibilizadas na documentação do programa TAC [San15], já que o objetivo final deste trabalho é que seja gerado um código no qual, ao ser executado por este programa, funcione da forma correta.

Basicamente, passando uma visão geral, o TAC [San15] possui duas seções principais, a tabela de símbolos (.table), onde são feitas as declarações de variáveis e constantes e a seção de código (.code) que armazena todas as funções e expressões presentes no programa.

Como todas as outras análises são feitas em uma única passagem, nesta também utilizei da mesma passagem para construir o código de três endereços (3AC). Dito isso, alterações na estrutura do nó da árvore foram necessárias, adicionando agora uma estrutura correspondente ao 3AC que armazena os dados utilizados para a construção do mesmo, como a operação, os argumentos e o destino.

Para que o programa seja executado da forma esperada foram criadas e prefixadas, no início da seção .code, algumas funções que podem ser utilizadas

durante a execução do TAC, como por exemplo as funções write e writeln para que seja possível escrever na tela uma string com múltiplos caracteres, ou seja, ao escrever uma string, ao invés de criar uma repetição toda vez, utilizase da função prefixada, passando como parâmetro o tamanho e o endereço da string a ser lida.

Além disso o TAC possui a maioria das operações básicas necessárias, porém algumas não estão inclusas já que podem ser obtidas alterando posições de operadores ou adicionando operações. Dito isso a operação relacional != consiste em uma negação da operação == e as operações > e >= são iguais as de < e <=, apenas alterando a ordem dos argumentos.

Vale abordar também que algumas operações como for, if e else precisam de rótulos para serem executadas de forma correta, sendo eles for\_&, end\_for\_&, end\_if\_& e end\_if\_else\_&, onde '&' é um número que os diferencia entre si, caso a exista mais de um if ou for.

Nas subseções a seguir serão abordados mais afundo decisões de projeto para a criação do código intermediário.

### 6.1 Variáveis e conversões de tipos

Para este projeto, sempre que houver uma declaração de variável ou string, essa declaração é armazenada na seção .table do TAC [San15]. Essas declarações são feitas utilizando o nome da variável e seu respectivo escopo (i.e: int x\_0, variável do tipo int, chamada 'x' e no escopo '0'), fazendo com que as operações funcionem da forma esperada, respeitando seus respectivos escopos.

Já para variáveis temporárias, que são criadas para a execução do programa, foram utilizados os registradores disponibilizados dentro da seção .code, estes são utilizados em ordem crescente (\$0, \$1, \$2, ...) e conforme são necessários.

Sobre as conversões de tipo, todas as operações passam por uma checagem de tipo antes de serem escritas, esta checagem utiliza das operações de coerção realizadas na análise semântica, traduzindo-as para a linguagem reconhecida pela TAC, definindo, assim, quais devem ser as conversões realizadas e executando-as, quando necessário, antes da operação, fazendo com que o código não possua problemas de tipagem.

### 6.2 Novas primitivas - set e elem

Para a nova primitiva elem são utilizados três espaços de memória na heap disponível no TAC, estes são responsáveis por armazenar o tipo do elemento, o seu valor e o endereço para o próximo elemento, caso necessário.

A primitiva set é um conjunto de elem's e para percorrer o set, utilizasse do endereço do próximo elemento armazenado dentro do elem.

As funções relacionadas a primitiva set também são prefixadas no início da seção. Para a função add verificamos primeiro se ele já está presente neste conjunto, caso contrário, o adicionamos. Para a função remove apenas percorrese a lista em busca do elemento, caso ele exista, o removemos, caso contrário,

a função retorna nulo. Já para a função in dois tipos de tratamentos foram necessários, um quando é utilizado dentro de um forall, que neste caso, ele retorna o primeiro elemento do set e vai modificando-o ao decorrer das iterações, outro quando é utilizado como uma operação booleana, que no caso deve-se percorrer a lista de elementos, se encontrar o valor solicitado retornar 1, caso contrário 0. Por fim, para a função is\_set apenas verifica-se o tipo do elemento dentro da heap, se for um set retorna 1, caso contrário, 0.

# 7 Descrição dos arquivos testes

Os testes se encontram na pasta testes/, os arquivos sucesso1.c e sucesso2.c, são testes que contém código correto, já os arquivos erro1.c e erro2.c contém códigos incorretos, sendo os seus erros, respectivamente:

```
1. SEMANTIC ERROR 3:9
                        - '+' operator do not supports
    the type SET
  SEMANTIC ERROR 4:7
                        - Redeclaration of variable 'b'
  SEMANTIC ERROR 14:3
                        - Incompatible types can't be
    casted -> SET to FLOAT
  SEMANTIC ERROR 14:3
                        - Fewer number of arguments in
    function 'a' - expected: 2 , received: 1
  SEMANTIC ERROR 15:3
                         - Incompatible types can't be
    casted -> INT to NULL
  SEMANTIC ERROR 15:3
                        - Greater number of arguments in
    function 'a' - expected: 2 , received: 3
  SEMANTIC ERROR - The program doens't have a 'main' function
2. LEXICAL ERROR
                  2:8
                        - Unidentified character: #
  SYNTAX ERROR
                  3:8
                        - syntax error, unexpected ';',
    expecting '='
  SYNTAX ERROR
                  3:14 - syntax error, unexpected ')'
                        - syntax error, unexpected INT_TYPE
  SYNTAX ERROR
                  9:3
  SEMANTIC ERROR 11:5
                        - Incompatible types can't be
    casted -> INT and SET
```

Basicamente, como é possível observar acima, os erros são apresentados e possuem a linha e coluna na qual eles pertencem (linha:coluna). O primeiro arquivo de erro - erro1.c - possui apenas erros semânticos, já o segundo arquivo - erro2.c - possui tanto erros léxicos, quanto erros sintáticos e semânticos.

Quando um arquivo possui apenas erros semânticos é apresentada a árvore sintática, porém caso existam erros sintáticos ou léxicos ela não é impressa. A tabela de símbolos gerada (que pode não estar completa dependendo do tipo dos erros) é sempre apresentada, independente do número de erros. Cada erro é apresentado seguido de uma descrição do mesmo e o código intermediário não é gerado se o programa possuir qualquer tipo de erro.

### 8 Instruções para compilação e execução do programa

O programa foi criado e testado em um sistema operacional Linux - Ubuntu 20.04.1 LTS. É necessária a instalação do FLEX [Est17] e do BISON [DS21] para a compilação do programa. Ao executar o programa também deverá ser passado o arquivo que será analisado. Além disso, para poder executar o código de três endereços gerado, é necessária, também, a instalação do TAC [San15].

Comandos para compilação e execução:

```
$ bison sintatico.y
$ flex lexico.l
$ gcc sintatico.tab.c lex.yy.c tabela.c arvore.c tac.c
$ ./a.out testes/<nome-arquivo>.c
$ ./tac output_tac/output.tac
```

Outra alternativa para facilitar a compilação seria utilizar o comando make. Abaixo segue as versões de cada software que foi utilizado para o desenvolvimento:

```
$ gcc --version
gcc (Ubuntu 9.3.0-17ubuntu1~20.04) 9.3.0
$ bison --version
bison (GNU Bison) 3.7.6
$ flex --version
flex 2.6.4
```

#### Referências

- [ALSU07] A.V. Aho, M.S. Lam, R. Sethi, and J.D. Ullman. *Compilers: Principles, Techniques, & Tools.* Pearson/Addison Wesley, 2nd edition, 2007.
- [DS21] C. Donnelly and R. Stallman. Bison the yacc-compatible parser generator, 2021. Online; Acessado 18 de março de 2021 https://www.gnu.org/software/bison/manual/bison.html.
- [Est17] W. Estes. Flex: Fast lexical analyzer generator, 2017. Online; Acessado 21 de fevereiro de 2021 https://github.com/westes/flex.
- [San15] L. Santos. Tac the three address code interpreter, 2015. Online; Acessado 6 de maio de 2021 https://github.com/lhsantos/tac.

### A Gramática

```
\langle program \rangle ::= \langle declaration \ list \rangle
\langle declaration\_list \rangle ::= \langle declaration \rangle \langle declaration\_list \rangle \mid \langle declaration \rangle
\langle declaration \rangle ::= \langle function \ declaration \rangle \mid \langle var \ declaration \rangle
\langle var\_declaration \rangle ::= \langle type \rangle \langle id \rangle ';'
\langle function \ declaration \rangle ::= \langle type \rangle \langle id \rangle '(' \langle params \ list \rangle')' \langle brackets \ stmt \rangle
        \langle type \rangle \langle id \rangle '(' ')' \langle brackets \ stmt \rangle
\langle params\_list \rangle ::= \langle type \rangle \langle id \rangle ',' \langle param\_list \rangle \mid \langle type \rangle \langle id \rangle
\langle stmts \rangle ::= \langle stmt \rangle \langle stmts \rangle | \langle stmt \rangle
\langle stmt \rangle ::= \langle for\_stmt \rangle \mid \langle if\_else\_stmt \rangle \mid \langle return\_stmt \rangle \mid \langle io\_stmt \rangle
         \langle brackets\_stmt \rangle
         \langle exp\_stmt \rangle
         \langle set \ stmt \rangle
          \langle var \ declaration \rangle
         \langle assignment \rangle ';'
\langle assignment \rangle ::= \langle id \rangle '=' \langle exp \rangle
\langle brackets \ stmt \rangle ::= `\{' \ \langle stmts \rangle \ `\}'
\langle io\_stmt \rangle ::= \text{ read '('} \langle id \rangle ')' ';'
         write ( \langle string \rangle \mid \langle exp \rangle \mid \langle char \rangle ) ;
         writeln' ('\langle string \rangle \mid \langle exp \rangle \mid \langle char \rangle')' ';'
\langle for\_stmt \rangle ::= \text{ for '('} \langle assignment \rangle ';' \langle exp \rangle ';' \langle assignment \rangle ')' \langle stmt \rangle
\langle if\_else\_stmt \rangle ::= if '(' \langle exp \rangle ')' \langle stmt \rangle
     if '(' \langle exp \rangle ')' \langle stmt \rangle else \langle stmt \rangle
\langle return\_stmt \rangle ::= return '; ' | return \langle exp \rangle '; '
\langle set \ stmt \rangle ::= \text{forall'}(' \langle id \rangle \text{ in } \langle set \ exp \rangle ')' \langle stmt \rangle
\langle exp\_stmt \rangle ::= \langle exp \rangle ';' | ';'
\langle exp \rangle ::= \langle or\_exp \rangle
\langle set\_exp \rangle ::= add'('\langle set\_in\_exp \rangle')'
        remove'(' \langle set\_in\_exp \rangle')'
        exists ( \langle set\_in\_exp \rangle )
\langle set\_aux\_exp \rangle ::= \langle id \rangle 'in' \langle or\_exp \rangle
\langle set\_in\_exp \rangle ::= \langle or\_exp \rangle 'in' \langle set\_exp \rangle \mid \langle or\_exp \rangle 'in' \langle id \rangle
\langle or \ exp \rangle ::= \langle or \ exp \rangle ' | | ' \langle and \ exp \rangle | \langle and \ exp \rangle | \langle set \ in \ exp \rangle
```

```
\langle and\_exp \rangle ::= \langle and\_exp \rangle '&&' \langle relational\_exp \rangle \mid \langle relational\_exp \rangle
\langle relational \ exp \rangle ::= \langle relational \ exp \rangle \langle relational \ op \rangle \langle sum \ exp \rangle | \langle sum \ exp \rangle
⟨relational op⟩ ::= '<' | '>' | '>=' | '<=' | '==' | '!='
\langle sum\_exp \rangle ::= \langle sum\_exp \rangle '+' \langle mul\_exp \rangle
       \langle sum\_exp \rangle '-' \langle mul\_exp \rangle
       \langle mul\_exp \rangle
\langle mul\_exp \rangle ::= \langle mul\_exp \rangle  '*' \langle primal\_exp \rangle
       \langle mul\_exp \rangle '/' \langle primal\_exp \rangle
   | \langle unary\_exp \rangle
\langle unary\_exp \rangle ::= \langle primal\_exp \rangle \mid `! \ \langle primal\_exp \rangle \mid `-' \ \langle primal\_exp \rangle
       '!'? \(\langle id\rangle \) '(' \(\text{arg_list '}\right)'
        '!'? \(\langle id\) '(' ')'
  | '!'? is_set '(' \langle id \rangle | \langle set\_exp \rangle ')'
\langle primal\_exp \rangle ::= \langle id \rangle \mid \langle const \rangle \mid `(` \langle exp \rangle `)` \mid \langle set\_exp \rangle
\langle arg\_list \rangle ::= \langle exp \rangle, \langle arg\_list \rangle \mid \langle exp \rangle
\langle type \rangle ::= \langle basic\_type \rangle \mid \langle elem\_type \rangle \mid \langle set\_type \rangle
\langle const \rangle ::= \langle int\_const \rangle \mid \langle float\_const \rangle \mid \langle empty\_const \rangle
\langle int\_const \rangle ::= \langle digit \rangle +
\langle float\_const \rangle ::= \langle digit \rangle + `.` \langle digit \rangle^*
\langle empty\_const \rangle ::= 'EMPTY'
\langle elem \ type \rangle ::= elem
\langle set\_type \rangle ::= set
\langle int\_type \rangle ::= int
\langle float\_type \rangle ::= float
\langle string \rangle ::= .*
\langle char \rangle ::= '.*'
\langle id \rangle ::= [a-zA-Z] [a-z0-9A-Z]^*
\langle digit \rangle ::= [0-9]
```